

对比维度 / 考点	MLP	CNN	RNN	LSTM	Transformer
更适合处理什么数据	固定长度向量、表格型输入。	图像、空间网格数据。	序列、文本、时序数据。	序列、文本、时序数据。	序列、文本。
输入怎么进入网络	整体向量一次送入。	局部窗口在空间上滑动进入。	逐 token 串行送入。	逐 token 串行送入。	整段 token 并行送入。
核心机制	全连接层 + 非线性激活。	卷积、局部连接、参数共享、池化。	隐藏状态递推。	记忆状态 + 遗忘门/输入门/输出门。	注意力机制 + 位置编码。
是否天然适合变长序列	否。	不天然适合文本式变长序列。	是。	是。	是。
是否有参数共享	没有。	有。卷积核在不同位置复用。	有。时间步共享 $U/W/V$ 。	有。	有。层内线性映射参数共享于各 token 位置。
历史/上下文信息怎么保留	没有专门记忆机制。	不靠时间记忆，主要抓局部空间结构。	通过隐藏状态 S_t 传递历史信息。	通过隐藏状态和记忆状态共同保留信息。	不靠递推隐藏状态，而是直接建模 token 间关系。
是否容易并行	容易。	空间并行好。	差。	差。	好。
最擅长什么	一般向量映射、分类/回归基础结构。	局部空间关联、层级特征提取。	顺序依赖、基础时序建模。	比 RNN 更强的长期信息保留。	全局关系、长距离依赖、并行训练。
典型局限	忽略图像空间结构，不擅长序列历史。	主要是局部感受野，不是天然时序模型。	长程依赖难保留；BPTT 训练困难。	仍然是串行结构。	注意力本身不带顺序，必须补位置编码。
一句话速记	整体看向量。	局部看图像。	按顺序传历史。	RNN 加门控记忆。	全局一起看 token 关系。
最核心的区分	看的是整体输入，不显式利用空间局部结构。	显式利用图像局部空间结构。	按时间顺序一步一步传历史。	仍然按顺序传，但更会保留长期信息。	直接让 token 两两建立关系，不靠一步一步传。
代表性公式/关键词	$y = \sigma(Wx + b)$ 。	$H_{out} = \lfloor \frac{H+2P-K}{S} \rfloor + 1$; C_{out} ; padding; stride。	$S_t = f(Ux_t + WS_{t-1} + b)$ 。	遗忘门、输入门、输出门; 记忆状态 C_t 。	$\text{softmax}(QK^T/\sqrt{d_k})V$; Q/K/V; causal mask; LayerNorm。
参数量会考什么	单层参数量: $d_{out}d_{in} + d_{out}$ 。	卷积参数量: $K \times K \times C_{in} \times C_{out} + C_{out}$ 。	参数量要把 U, W, V, b, c 算全。	这份对比表里不展开整套参数量，只记住比 RNN 结构更复杂。	这份对比表里不展开整层参数量，考试重点更常落在 Q/K/V、mask、位置编码。
公式会怎么考	常考单层形式、参数量、激活函数为什么需要。	常考输出尺寸、参数量、padding/stride、输出通道数。	常考状态更新公式、参数共享、参数量。	更常考三类门的作用，而不是整套门公式推导。	常考注意力公式、Q/K/V 含义、位置编码、causal mask。
判断题最爱挖什么坑	如果层间全是线性，多层整体仍等价线性变换; 必须有激活函数才真正增加非线性表达能力。	padding 不会增加可学习参数; 池化不是必须层; stride 为 2 的卷积可以同时做特征提取和下采样。	能处理变长序列，是因为同一组参数在所有时间步共享，不是因为不同时间步使用不同权重。	LSTM 不是为了让序列“变短”，而是为了更好地保留长期信息; 截断 BPTT 和 LSTM 解决的问题不同。	注意力机制本身不关心顺序，所以必须加入位置编码; causal mask 是为了不能看未来 token。

对比维度 / 考点	MLP	CNN	RNN	LSTM	Transformer
填空题高频抓手	参数量；偏置 b ；激活函数是逐元素作用。	卷积核个数决定输出通道数；padding/stride 如何影响输出大小；池化通常没有可学习参数。	参数共享；当前状态依赖当前输入和上一时刻隐藏状态。	遗忘门决定保留多少旧记忆；输入门决定写入多少新信息；输出门决定输出多少记忆信息。	位置编码表示顺序；Q/K/V 中 V 是被汇总的信息；LayerNorm 逐 token 计算；causal mask 遮住未来位置。
最容易混的点	不能说 MLP 天然适合图像和文本序列。	卷积核个数决定输出通道数；池化不是必须层。	能处理变长靠参数共享和重复使用同一单元，不是因为长度固定，也不是因为参数量会随时间步增加。	LSTM 解决的是长期信息难保留，不是“序列太长就完全不能训练”。	self-attention 中 Q/K/V 来自同一序列；位置编码不是给词义，而是给顺序；Q 和 K 最后一维必须相同。
和前一个模型相比多了什么	作为基础结构，本身就是很多网络模块的出发点。	比 MLP 多了显式利用空间局部结构的能力。	比 MLP/CNN 多了顺序递推和历史记忆。	比 RNN 多了记忆状态和门控机制。	比 RNN/LSTM 多了全局建模和并行处理能力。
最容易混的 4 组区别	1. MLP vs CNN ：关键不是“层数多少”，而是有没有显式利用空间局部结构。MLP 整体看向量，CNN 用局部卷积窗口看图像。 2. RNN vs LSTM ：二者都按时间步串行处理序列；LSTM 比 RNN 多了记忆状态和门控机制，所以更容易保留长期信息。 3. LSTM vs Transformer ：LSTM 仍然是串行传历史；Transformer 不靠一步一步传，而是直接计算 token 之间的关系。 4. CNN vs Transformer ：CNN 主要利用局部空间结构；Transformer 主要利用 token 之间的全局关联关系。				
口头速答模板	如果老师口头问“这几种网络到底差别是什么”，最短回答可以是： MLP 适合固定向量；CNN 适合图像局部结构；RNN 适合按顺序处理序列；LSTM 是更能保长期信息的 RNN；Transformer 用注意力直接建模 token 之间关系，而且更适合并行。				
最后一遍串讲	先分数据类型：固定向量更像 MLP，图像更像 CNN，文本序列更像 RNN/LSTM/Transformer。 再分信息传播方式：CNN 主要看局部空间邻域；RNN/LSTM 串行传历史；Transformer 直接让 token 两两建立关系。 最后抓考试关键词：MLP 看参数量，CNN 看尺寸和参数量，RNN 看参数共享和状态公式，LSTM 看三类门，Transformer 看 Q/K/V、位置编码、causal mask 和 LayerNorm。				