

五大网络对比

袁肖赞，上海交通大学计算机学院，yuanxiaoyun@sjtu.edu.cn

Contents

1 五大网络对比	1
1.1 考试对比细表	1
1.2 数据分流总图	3
1.3 常考知识点与考点整理	4
1.4 极简速记版	5

1 五大网络对比

这份讲义怎么用：先看第 1 页大总表，快速区分五种网络；再看第 2 页总图，理解它们为什么不同；最后看第 3-4 页，把最常考的公式点、判断点和速记句子一起抓住。


1.1 考试对比细表

最容易混的 4 组区别

1. **MLP vs CNN**：关键不是“层数多少”，而是有没有显式利用空间局部结构。MLP 整体看向量，CNN 用局部卷积窗口看图像。
2. **RNN vs LSTM**：二者都按时间步串行处理序列；LSTM 比 RNN 多了记忆状态和门控机制，所以更容易保留长期信息。
3. **LSTM vs Transformer**：LSTM 仍然是串行传历史；Transformer 不靠一步一步传，而是直接计算 token 之间的关系。
4. **CNN vs Transformer**：CNN 主要利用局部空间结构；Transformer 主要利用 token 之间的全局关联关系。

模型	更适合处理什么数据	输入怎么进入网络	核心机制	是否天然适合变长序列	是否有参数共享	历史/上下文信息怎么保留	是否容易并行	最擅长什么	典型局限	代表性公式/关键词	常考易错点	一句话速记
MLP	固定长度向量、表格型输入	整体向量一次送入	全连接层、非线性激活	否	无	没有专门记忆机制	容易	一般向量映射、分类/回归基础结构	忽略图像空间结构，不擅长序列历史	$y = \sigma(Wx + b)$; 参数量 $d_{out}d_{in} + d_{out}$	不能说 MLP 天然适合图像和文本序列；若层间全是线性，多层整体仍等价线性变换	整体看向量
CNN	图像、空间网格数据	局部窗口在空间上滑动	卷积、局部连接、参数共享、池化	不天然适合文本式变长序列	有，卷积核在不同位置复用	不靠时间记忆，主要抓局部空间结构	空间并行好	局部空间关联、层级特征提取	主要是局部感受野，不是天然时序模型	$H_{out} = \lfloor \frac{H+2P-K}{S} \rfloor + 1$; C_{out} ; padding; stride	卷积核个数决定输出通道数；池化不是必须层；stride 为 2 的卷积可做学习下采样	局部看图像
RNN	序列、文本、时序数据	逐 token 串行送入	隐藏状态递推	是	有，时间步共享 $U/W/V$	通过隐藏状态 S_t 传递历史信息	差	顺序依赖、基础时序建模	长程依赖难保留；BPTT 训练困难	$S_t = f(Ux_t + WS_{t-1} + b)$	能处理变长靠参数共享和重复使用同一单元，不是因为序列长度固定，也不是因为参数量会随时间步增加	按顺序传历史
LSTM	序列、文本、时序数据	逐 token 串行送入	记忆状态 + 遗忘门/输入门/输出门	是	有	通过隐藏状态和记忆状态共同保留信息	差	比 RNN 更强的长期信息保留	仍然是串行结构	遗忘门、输入门、输出门；记忆状态 C_t	LSTM 解决的是长期信息难保留，不是“序列太长就完全不能训练”；截断 BPTT 和 LSTM 解决的问题不同	RNN 加门控记忆
Transformer	序列、文本	整段 token 并行送入	注意力机制 + 位置编码	是	有，层内线性映射参数共享于各 token 位置	不靠递推隐藏状态，而是直接建模 token 间关系	好	全局关系、长距离依赖、并行训练	注意力本身不带顺序，必须补位置编码	$\text{softmax}(QK^T/\sqrt{d_k})$; Q/K/V; causal mask; LayerNorm	self-attention 中 Q/K/V 来自同一序列；位置编码不是给词义，而是给顺序；Q 和 K 最后一维必须相同	全局一起看 token 关系

1.2 数据分流总图



怎么顺着这张图讲：先问“数据长什么样”。如果是固定长度向量，最自然想到 MLP；如果是图像，最关键的是空间局部结构，所以常想到 CNN；如果是文本或时序，最关键的是顺序，于是进入序列模型。序列模型里，RNN/LSTM 依靠串行传递历史，Transformer 则直接让所有 token 建立关系，再靠位置编码补上顺序。

1.3 常考知识点与考点整理

公式会考什么

模型	考试最可能考的公式点
----	------------

MLP	单层形式 $y = \sigma(Wx + b)$; 参数量 $d_{out}d_{in} + d_{out}$ 。
CNN	输出空间尺寸 $H_{out} = \lfloor \frac{H+2P-K}{S} \rfloor + 1$; 参数量 $K \times K \times C_{in} \times C_{out} + C_{out}$ 。
RNN	状态更新 $S_t = f(Ux_t + WS_{t-1} + b)$; 参数量要把 U, W, V, b, c 算全。
LSTM	不要求整套门公式全背, 但要记住遗忘门、输入门、输出门各自控制什么。
Transformers	$\text{softmax}(QK^T/\sqrt{d_k})V$; Q/K/V 各自含义; 位置编码加到 embedding 上。

判断题爱怎么挖坑

1. **MLP**: 如果每层都只有线性变换, 多层整体仍等价于一个线性变换; 必须有激活函数才真正增加非线性表达能力。
2. **CNN**: padding 不会增加可学习参数; 池化不是必须层; stride 为 2 的卷积可以同时做特征提取和下采样。
3. **RNN**: 能处理变长序列, 是因为同一组参数在所有时间步共享, 不是因为不同时间步使用不同权重。
4. **LSTM**: LSTM 不是为了让序列“变短”, 而是为了更好地保留长期信息; 截断 BPTT 解决的是训练回传太长的问題。
5. **Transformer**: 注意力机制本身不关心顺序, 所以必须加入位置编码; self-attention 中 Q/K/V 来自同一段序列; causal mask 是为了不能看未来 token。

填空题爱问什么

模型	高频填空抓手
----	--------

MLP	参数量; 偏置 b ; 激活函数是逐元素作用。
CNN	卷积核个数决定输出通道数; padding/stride 如何影响输出大小; 池化通常没有可学习参数。
RNN	参数共享; 当前状态依赖当前输入和上一时刻隐藏状态。
LSTM	遗忘门决定保留多少旧记忆; 输入门决定写入多少新信息; 输出门决定输出多少记忆信息。
Transformer	位置编码表示顺序; Q/K/V 中 V 是被汇总的信息; LayerNorm 是逐 token 计算; causal mask 遮住未来位置。

最短口头区分法

如果老师口头问你一句“这几种网络到底差别是什么”, 最短回答可以是:

MLP 适合固定向量; CNN 适合图像局部结构; RNN 适合按顺序处理序列; LSTM 是更能保长期信息的 RNN; Transformer 用注意力直接建模 token 之间关系, 而且更适合并行。

1.4 极简速记版

MLP

处理对象：固定长度向量。核心机制：全连接 $y = \sigma(Wx + b)$ 。一句话区分：整体看输入，不专门利用空间结构，也不专门记忆历史。

CNN

处理对象：图像、空间网格数据。核心机制：卷积、局部连接、参数共享、池化。一句话区分：用局部卷积窗口抓图像空间结构。

RNN

处理对象：序列、文本、时序数据。核心机制：隐藏状态递推 $S_t = f(Ux_t + WS_{t-1} + b)$ 。一句话区分：按时间顺序一步一步传历史。

LSTM

处理对象：序列、文本、时序数据。核心机制：记忆状态 + 遗忘门/输入门/输出门。一句话区分：在 RNN 上加入门控记忆，更容易保留长期信息。

Transformer

处理对象：序列、文本。核心机制：注意力机制 + 位置编码。一句话区分：让 token 直接全局建立关系，并行处理整段序列。

最后一遍串讲

先分数据类型：固定向量更像 MLP，图像更像 CNN，文本序列更像 RNN/LSTM/Transformer。

再分信息传播方式：CNN 主要看局部空间邻域；RNN/LSTM 串行传历史；Transformer 直接让 token 两两建立关系。

最后抓考试关键词：MLP 看参数量，CNN 看尺寸和参数量，RNN 看参数共享和状态公式，LSTM 看三类门，Transformer 看 Q/K/V、位置编码、causal mask 和 LayerNorm。