

人工智能期末复习课短版

袁肖赞，上海交通大学计算机学院人工智能研究院，yuanxiaoyun@sjtu.edu.cn

Contents

1 使用方式	1
2 公式与计算	2
2.1 基础公式	2
2.2 CNN 公式	2
2.3 RNN、Attention 与 RL 公式	3
3 基础与残差网络	3
4 卷积神经网络 CNN	3
5 RNN 与 LSTM	4
6 Transformer	4
7 训练现象：频率、凝聚、平坦性	4
8 大模型	5
9 强化学习	5
10 考前自测	6
11 最后只背这些	6

1 使用方式

这份短版适合考前几天突击。它不替代详细版，而是把最容易考成选择题、判断题、填空题和简单计算题的内容压缩到一起。

复习顺序：先背公式和关键结论，再做最小计算模板，最后用高频判断句查漏。

建议：

- 只剩 1 天：看第 1、2、10 节。
- 还有 2 到 3 天：按第 3 到 9 节逐章过一遍。
- 遇到不理解点，再回详细版对应章节看图和例子。

2 公式与计算

2.1 基础公式

- 全连接层：

$$y = Wx + b, \quad W \in R^{d_{out} \times d_{in}}, \quad b \in R^{d_{out}}$$

参数量为 $d_{out}d_{in} + d_{out}$ 。

- **ReLU**：

$$\text{ReLU}(x) = \max(0, x)$$

负数变 0，正数不变；激活函数逐元素作用。

- **Softmax**：

$$p_i = \frac{e^{z_i}}{\sum_j e^{z_j}}$$

把 logits 变成概率，所有概率和为 1；大的更大，小的更小，更接近 one-hot。

- 二分类交叉熵：

$$H(y, p) = -\frac{1}{n} \sum_{i=1}^n [y_i \log f_{\theta}(x_i) + (1 - y_i) \log(1 - f_{\theta}(x_i))]$$

- 多分类交叉熵：

$$H(y, p) = -\frac{1}{n} \sum_{i=1}^n \sum_{c=1}^C y_{i,c} \log p_{i,c}$$

真实类别概率越大，loss 越小。

- 残差连接：

$$y = x + F(x)$$

保留原输入信息，使深层网络更容易训练。

2.2 CNN 公式

- 卷积输出大小：

$$H_{out} = \left\lfloor \frac{H + 2P - K}{S} \right\rfloor + 1, \quad W_{out} = \left\lfloor \frac{W + 2P - K}{S} \right\rfloor + 1$$

H, W 是输入高和宽， K 是卷积核大小， P 是 padding， S 是 stride。

- 输出通道数：输出通道数由卷积核个数决定，通常记为 C_{out} 。
- 卷积参数量：

$$\#params = K^2 C_{in} C_{out} + C_{out}$$

最后的 C_{out} 是 bias；参数量不乘输出高和宽。

- 多通道卷积：

$$Y_j = \sum_{c=1}^{C_{in}} X_c * K_{j,c} + b_j, \quad j = 1, \dots, C_{out}$$

* 表示空间卷积； $K_{j,c} \in R^{K \times K}$ 是第 j 个 filter 在第 c 个输入通道上的卷积核切片。

2.3 RNN、Attention 与 RL 公式

- RNN 状态更新:

$$S_t = f(Ux_t + WS_{t-1} + b), \quad y_t = g(VS_t + c)$$

U, W, V, b, c 在所有时间步共享, 所以序列变长时参数数量不随时间步增加。

- 缩放点积注意力:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

先用 QK^T 算相关性, 再 softmax 成权重, 最后对 V 加权求和。

- 折扣回报:

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

γ 越大越重视长期奖励。

- 价值函数:

$$V^\pi(s) = \mathbb{E}_\pi[G_t | S_t = s], \quad Q^\pi(s, a) = \mathbb{E}_\pi[G_t | S_t = s, A_t = a]$$

- Bellman 方程:

$$V = R + \gamma PV$$

V 是状态价值向量, R 是奖励向量, P 是状态转移矩阵。

3 基础与残差网络

参数: 神经网络中通过训练学习的数, 典型是权重 W 和偏置 b ; 偏置不是手工常数, 而是可学习参数。

激活函数: 激活函数提供非线性; 如果没有非线性, 多层线性变换整体仍等价于一层线性变换。

- 单个神经元常写成 $z = w^T x + b$, 再经过激活函数输出。
- 全连接层可以看成多个并行神经元。
- 深层网络可能出现梯度消失、梯度爆炸和退化; 退化指更深的网络训练效果反而更差。
- 残差连接不是为了减少参数, 也不是直接解决过拟合; 它的核心作用是让信息和梯度更容易传播。

4 卷积神经网络 CNN

CNN: CNN 利用图像的局部关联性和参数共享, 用局部卷积窗口提取空间特征。

- 图像有局部关联性: 相邻像素关系强, 距离越远关系越弱; 图像数据更接近幂律衰减关联。
- 图像任务常希望对平移、旋转、缩放有一定不变性, 但图像像素顺序不能随便打乱。
- CNN 与 MLP 的区别: MLP 通常全连接, 参数多; CNN 使用局部连接和参数共享, 更适合图像。
- 卷积核是可训练小窗口, 同一个卷积核在整张图上滑动。
- Padding 控制边缘和输出大小, 不增加可学习参数。
- Stride 是滑动步长; stride 越大, 输出空间尺寸越小。
- Stride 为 2 的卷积可以做可学习下采样, 也就是卷积和类似 pooling 的降采样合在一起。
- 池化通常没有可学习参数; max pooling 取最大值, mean pooling 取平均值。
- 1×1 卷积主要改变通道数或做通道间线性组合。
- 卷积、激活、池化、全连接等层可以灵活搭配, 没有固定网络格式。

卷积计算模板。输入 $32 \times 32 \times 3$, $K = 3$, padding=1, stride=1, 卷积核个数 $C_{out} = 16$, 输出为 $32 \times 32 \times 16$ 。参数数量为 $3^2 \times 3 \times 16 + 16 = 448$ 。

5 RNN 与 LSTM

RNN: RNN 按时间步处理序列, 用隐藏状态保存历史信息, 同一组参数在不同时间步共享。

LSTM: LSTM 是改进的 RNN, 用记忆状态和门控机制缓解长程依赖和梯度问题。

- 文本是离散符号序列, 长度可变, 有顺序、上下文和长程依赖。
- RNN 能处理变长序列的核心是参数共享: 序列变长只增加计算步数, 不增加参数数量。
- Tokenization 把原始文本变成 token 序列。
- One-hot 高维稀疏, 只表示编号; embedding 低维稠密、可训练, 可表达语义相似性。
- Embedding 矩阵大小为 $|V| \times d$, one-hot 乘这个矩阵得到对应词向量。
- Next Token Prediction 用前文预测下一个 token, 标签来自文本本身, 属于自监督学习, 常用交叉熵。
- BPTT 是沿时间展开后的网络反向传播; 长链式相乘容易导致梯度消失或爆炸。
- LSTM 三个门: 遗忘门保留旧记忆, 输入门写入新信息, 输出门控制输出信息。
- LSTM 常见设计原则: 先做线性变换; 门用 sigmoid; 候选信息常用 tanh。

6 Transformer

Transformer: Transformer 以注意力机制为核心, 能够并行处理 token, 并直接建模 token 之间的关系。

位置编码: 注意力机制本身不关心顺序, 所以要给 token 加入位置信息; 输入通常是 embedding 加位置编码。

- RNN/LSTM 通常串行处理 token; Transformer 可以并行输入、并行输出。
- Q 是 Query, 表示要查什么; K 是 Key, 表示可被匹配的标识; V 是 Value, 表示被汇总的信息。
- 在 self-attention 中, Q, K, V 都由同一个输入 X 乘可训练矩阵得到。
- Q 和 K 的最后一维必须相同, 因为要做点积; K 和 V 的数量必须相同, 因为一个 key 对应一个 value。
- 注意力四步: 线性映射得到 $Q/K/V$; QK 点积算关联强度; softmax 得到权重; 权重对 V 加权求和。
- W^O 把 attention 输出映射回模型维度, 方便和输入做残差相加。
- Causal mask 遮住未来 token, 保证生成当前位置时不能提前看到答案。
- LayerNorm 是逐 token 在特征维度内归一化, 不在 token 之间算均值方差。
- FNN 是逐 token 的 MLP; token 之间的信息交互主要发生在 attention 中。
- 贪婪解码每步取最大概率 token; 采样解码按概率抽样, 同一输入可能有不同输出。

7 训练现象: 频率、凝聚、平坦性

频率原则: 神经网络训练通常先学习低频成分, 再学习高频成分。

平坦解: 参数附近一片区域 loss 都较低, 扰动后仍稳定, 通常泛化更好。

- 函数可看成不同频率成分叠加；低频变化慢、平滑，高频变化快、振荡、细节多。
- 判断频率原则时要控制幅值影响，比较同幅值、不同频率的成分。
- 早停可以减少对高频噪声的过度拟合。
- 两种频率要区分：图像频率描述像素变化快慢；响应频率描述模型输出对输入扰动的敏感程度。
- 过参数化模型参数很多，但训练仍可能得到有规律、可泛化的解；这和优化隐式偏置有关。
- 全零初始化通常不可取，因为同层神经元会保持对称。
- 小初始化下，同层 ReLU 神经元方向和转折点可能趋同，这叫参数凝聚。
- 转折点相同的 ReLU 神经元可以合并理解；不同转折点提供不同非线性位置。
- 尖锐解附近 loss 变化快，扰动后不稳定；平坦解更鲁棒。
- 小批量梯度噪声有助于跳出尖锐区域；合理较大的学习率更容易得到平坦解，但太大会不收敛。

8 大模型

基础模型：基础模型是参数量大、经过大规模数据训练、可适应多种下游任务的模型。

- 大语言模型以文本 token 为主要输入输出；多模态数据也可以 token 化。
- Encoder-only 看双向上下文，适合理解任务，代表 BERT。
- Decoder-only 使用 causal mask，只看当前及以前 token，适合生成任务，代表 GPT、Llama、DeepSeek。
- Encoder-Decoder 先编码输入再解码输出，适合翻译、摘要等任务。
- 预训练学习通用语言和知识能力；SFT 用标注指令数据继续训练。
- 强化学习后训练可增强推理或对齐偏好，不是用来取代预训练，也不是直接缩短响应时间。
- 提示词工程改输入提示，通常不更新模型参数。
- 知识蒸馏让 Student model 学习 Teacher model，用于压缩和部署。
- Scaling law 描述规模、数据、算力增加时测试损失通常按幂律下降。
- 上下文学习不更新参数；思维链输出中间推理步骤；幻觉是看似合理但实际错误的生成内容。
- 初始化会影响训练路径和推理能力；课件例子中，小初始化通常更有利于学习可泛化规律。

9 强化学习

强化学习：强化学习是智能体在环境中采取动作、获得奖励并转移到新状态，通过试错学习最大化期望回报的方法。

- 强化学习是决策型任务；监督学习是预测型任务。
- 强化学习依赖奖励反馈，不依赖每一步的标注标签；奖励可能延迟出现。
- 状态是环境完整信息；观察是智能体实际看到的信息，可能只是状态的一部分。
- 动作空间可以离散，也可以连续。
- 情节型任务有终止状态；连续型任务没有固定终止状态。
- 探索是尝试未知动作获取信息；利用是选择当前认为更优的动作。
- 马尔可夫性：给定当前状态后，未来状态分布只依赖当前状态；有动作时，下一状态只依赖当前状态和当前动作。
- MDP 常包含状态、动作、转移概率、奖励和折扣因子。
- 策略 $\pi(a|s)$ 表示在状态 s 下选择动作 a 的规则。
- $V^\pi(s)$ 是从状态 s 出发的期望回报； $Q^\pi(s, a)$ 是先采取动作 a 后的期望回报。
- DP 通常需要环境模型和转移概率；MC 通过多次采样取平均，方差较大。
- 深度强化学习用神经网络近似价值函数或策略；DQN 用神经网络拟合 Q 值。
- RLHF 用人类偏好构造奖励信号，使大模型输出更符合人类偏好和价值观。

回报计算模板。若未来三个奖励为 1, 0, 2, $\gamma = 0.5$, 则

$$G_t = 1 + 0.5 \times 0 + 0.5^2 \times 2 = 1.5$$

10 考前自测

- 判断: 没有激活函数时, 多层线性网络整体仍等价于线性变换。答案: 正确。
- 填空: 卷积层输出通道数由 _____ 决定。答案: 卷积核个数或 C_{out} 。
- 判断: 卷积参数量要乘输出特征图的高和宽。答案: 错误。
- 填空: RNN 能处理变长序列的重要原因是所有时间步 _____。答案: 共享参数。
- 判断: Embedding 是可训练矩阵, one-hot 乘 embedding 矩阵得到词向量。答案: 正确。
- 填空: LSTM 中控制保留旧记忆的是 _____ 门。答案: 遗忘门。
- 判断: Transformer 不需要位置编码, 因为 attention 自动知道 token 顺序。答案: 错误。
- 填空: 注意力公式中, Q 和 K 的最后一维必须相同, 因为要做 _____。答案: 点积。
- 判断: LayerNorm 在不同 token 之间计算均值和方差。答案: 错误。
- 填空: 频率原则指神经网络训练通常先学习 _____ 频, 再学习 _____ 频。答案: 低; 高。
- 判断: 平坦解通常比尖锐解对参数扰动更稳定。答案: 正确。
- 判断: Decoder-only 适合自回归生成任务, 通常使用 causal mask。答案: 正确。
- 填空: 强化学习的目标是最大化期望 _____。答案: 回报。
- 判断: 马尔可夫性表示未来状态分布只依赖当前状态, 而不依赖完整历史。答案: 正确。
- 填空: Bellman 方程矩阵形式为 _____。答案: $V = R + \gamma PV$ 。

11 最后只背这些

- 基础: 参数、偏置、激活函数、softmax、交叉熵、残差连接。
- CNN: 局部连接、参数共享、padding、stride、输出尺寸、参数量、池化、 1×1 卷积。
- RNN/LSTM: 变长序列、参数共享、tokenization、embedding、RNN 公式、BPTT、LSTM 三个门。
- Transformer: 并行、位置编码、 $Q/K/V$ 、scaled dot-product attention、causal mask、LayerNorm、FNN。
- 训练现象: 频率原则、早停、参数凝聚、平坦解、小批量和大学习率。
- 大模型: 三种架构、预训练、SFT、RL 后训练、知识蒸馏、scaling law、上下文学习、思维链、幻觉。
- 强化学习: 状态、动作、奖励、回报、探索利用、MDP、策略、价值函数、Bellman、DP/MC/DQN/RLHF。