

人工智能期末复习课详细提纲

Contents

1	复习课总目标	2
2	残差网络基础	3
2.1	残差网络 ResNet	3
2.2	思考题	3
3	卷积神经网络 CNN	3
3.1	图像数据的特征：关联性	3
3.2	图像数据的特征：不变性	4
3.3	大脑如何处理图像：类视皮层设计	4
3.4	卷积运算	4
3.5	Zero Padding	5
3.6	Stride	6
3.7	多通道卷积	6
3.8	卷积层尺寸计算总结	7
3.9	池化 Pooling	9
3.10	CNN 整体结构与层的组合	9
3.11	关键记忆	10
3.12	思考题	10
4	循环神经网络 RNN 与 LSTM	10
4.1	自然语言处理 NLP 的任务特点	10
4.2	数据准备	11
4.3	分词、one-hot 与 embedding	12
4.4	Next Token Prediction	13
4.5	RNN 的设计	14
4.6	BPTT 与梯度问题	15
4.7	LSTM	15
4.8	关键记忆	16
4.9	思考题	17
5	Transformer	17
5.1	为什么需要 Transformer	17
5.2	Embedding 与位置编码	17
5.3	注意力机制直观理解	17
5.4	Q、K、V	18
5.5	Causal Mask	18
5.6	Transformer Block、FNN 与输出	18
5.7	关键记忆	18
5.8	思考题	19
6	神经网络训练现象：频率原则	19
6.1	过参数化与隐式偏好	19
6.2	频率、低频与高频	19

6.3	频率原则	19
6.4	早停 Early stopping	20
6.5	思考题	20
7	参数凝聚与解的平坦性	20
7.1	初始化大小的影响	20
7.2	参数凝聚	20
7.3	平坦解与尖锐解	21
7.4	思考题	21
8	大模型介绍	21
8.1	什么是大模型	21
8.2	Encoder、Decoder 与常见架构	22
8.3	预训练、微调、提示词、蒸馏	22
8.4	大模型中的现象	22
8.5	思考题	23
9	强化学习	23
9.1	强化学习是什么	23
9.2	状态、观察、动作空间、奖励	23
9.3	回报与折扣因子	24
9.4	情节型任务与连续型任务	24
9.5	探索与利用	25
9.6	策略、价值函数与最优策略	25
9.7	MDP 与马尔可夫性	25
9.8	Bellman 方程的直观含义	25
9.9	DP、MC 与深度强化学习	26
9.10	强化学习应用	26
9.11	思考题	27
10	最后一遍串讲清单	27
10.1	残差网络必会	27
10.2	CNN 必会	27
10.3	RNN/LSTM 必会	27
10.4	Transformer 必会	28
10.5	训练现象必会	28
10.6	大模型必会	28
10.7	强化学习必会	28
11	不建议作为考试重点的内容	29
12	两节复习课建议讲法	29
12.1	第一节课：网络结构主线	29
12.2	第二节课：训练现象、大模型、强化学习	29

适用对象：大一下学生。

适用题型：选择题、判断题、填空题。

复习定位：这份提纲不是题库，而是复习课讲授顺序。提纲采用“章级大知识点 -> 小知识点 -> 关键记忆 -> 思考题”的层次组织。

考试边界：从卷积神经网络开始到强化学习为主；第 11-12 节只保留残差网络相关基础。课件中标记为“阅读材料”的内容不作为复习重点。

1 复习课总目标

学生复习完后，应当能做到：

1. 看到一个神经网络结构名，能说出它解决什么类型的问题。

2. 看到一个模块名，能说出它在网络中的作用。
3. 看到一个容易混淆的说法，能判断对错并说出原因。
4. 对 CNN 能完成最简单的输出尺寸、通道数、参数量计算。
5. 对强化学习能说清状态、动作、奖励、策略、价值函数、回报、MDP 的含义。
6. 对大模型能说清预训练、微调、上下文学习、思维链、幻觉等基本概念。

2 残差网络基础

第 11-12 节中，全连接神经网络的细节不作为复习重点；这里只保留残差网络相关内容，作为理解深层网络训练困难的基础。

2.1 残差网络 ResNet

复习重点：

1. 深层普通网络不一定比浅层网络好，可能出现退化问题。
2. 退化问题指网络加深后训练误差和测试误差反而变差。
3. 深层网络还可能遇到梯度消失或梯度爆炸。
4. 残差连接让网络学习 $F(x) + x$ 。
5. 如果额外层学不到有用特征，至少可以更容易近似恒等映射。
6. 残差连接帮助信息和梯度在深层网络中传播。
7. 残差网络的核心不是“堆更多层一定更好”，而是让深层网络更容易训练。

关键表述：

普通层：输出 = $F(x)$

残差层：输出 = $F(x) + x$

易错点：

1. 残差连接不是简单地让网络“变浅”，而是让网络更容易学习恒等映射和优化深层结构。
2. 残差连接本身不一定显著增加参数量。
3. ResNet 不是只用于解决过拟合，它主要缓解深层网络训练困难和退化问题。
4. 深层普通网络表现变差不一定是因为表达能力不足，也可能是优化更困难。

2.2 思考题

1. 判断：残差连接的形式可以写成 $F(x) + x$ 。
答案：正确。
2. 判断：普通深层网络训练效果变差，一定是因为网络表达能力不够。
答案：错误。也可能是优化更困难、梯度传播更困难。
3. 填空：残差网络希望让额外层更容易学习一种特殊映射，叫做 _____ 映射。
答案：恒等。
4. 选择：ResNet 主要缓解的问题是：A. 图像颜色太多 B. 深层网络训练困难 C. 数据集文件太大 D. 类别数太少。
答案：B。
5. 判断：残差连接本身的核心作用是让信息和梯度更容易在深层网络中传播。
答案：正确。

3 卷积神经网络 CNN

这一章按 PDF 顺序复习：图像特性 -> 类视皮层启发 -> 卷积计算 -> padding -> stride -> 多通道卷积 -> 池化 -> CNN 结构。页码均指本章 PDF 页码。

3.1 图像数据的特征：关联性

页码：p3-p5

图像有空间结构。相邻像素通常更相关，距离越远，关联通常越弱。

模型	形式	记忆
指数衰减	$y = e^{-kx}$	下降较快
幂级数衰减	$y = \frac{1}{x^k}$	下降较慢，长程关联更明显

幂级数衰减可以看作许多指数衰减成分的叠加：

$$\int_0^\infty e^{-\alpha t} d\alpha = \frac{1}{t}$$

3.2 图像数据的特征：不变性

页码：p6

图像识别不应只记住像素位置。物体轻微平移、局部扰动或光照稍变时，类别通常不应改变。

3.3 大脑如何处理图像：类视皮层设计

页码：p7-p10

图像处理可以理解为：先提取局部简单特征，再逐步整合成复杂信息。

类比对象	作用	CNN 中的对应模块
简单细胞	对位置、边缘、方向敏感	卷积层
复杂细胞	整合多个局部输入	池化、全连接等后续模块

CNN 模块	作用
卷积层	提取局部特征
池化层	汇总局部信息
全连接层	综合特征
输出层	输出类别或概率

3.4 卷积运算

页码：p11-p13

卷积核是一个小窗口，例如 3×3 。它在图像上滑动，每次覆盖一个局部区域，把局部区域和卷积核对应位置相乘后求和。

3.4.1 单通道卷积示意

图像局部区域 X	卷积核 K
1 2 0	1 0 -1
3 1 2	1 0 -1
0 1 1	1 0 -1

$$\begin{aligned}
 &\text{一次卷积输出} = \\
 &1 \times 1 + 2 \times 0 + 0 \times (-1) \\
 &+ 3 \times 1 + 1 \times 0 + 2 \times (-1) \\
 &+ 0 \times 1 + 1 \times 0 + 1 \times (-1) \\
 &= 1
 \end{aligned}$$

卷积运算



右边的例子中用的是 $g(-u, -v)$, 是否等价?

是等价, 本质上, 做个变量代换即可。

$$F(x, y) = \sum_{u, v} f(x - u, y - v)g(u, v)$$

$$F(x, y) = \int f(x - u, y - v)g(u, v)du dv$$

卷积核

$g(-1, 1)$	$g(0, 1)$	$g(1, 1)$
$g(-1, 0)$	$g(0, 0)$	$g(1, 0)$
$g(-1, -1)$	$g(0, -1)$	$g(1, -1)$

图像

	$(x-1, y+1)$	$(x, y+1)$	$(x+1, y+1)$	
	$(x-1, y)$	(x, y)	$(x+1, y)$	
	$(x-1, y-1)$	$(x, y-1)$	$(x+1, y-1)$	

$$F(x, y) = f(x-1, y+1)g(-1, 1) + f(x, y+1)g(0, 1) + f(x+1, y+1)g(1, 1) \\ + f(x-1, y)g(-1, 0) + f(x, y)g(0, 0) + f(x+1, y)g(1, 0) \\ + f(x-1, y-1)g(-1, -1) + f(x, y-1)g(0, -1) + f(x+1, y-1)g(1, -1)$$

[1] 《深度学习现象导论》许志钦、张耀宇 https://github.com/xuzhiqin1990/understanding_dl



Figure 1: p11 卷积核在图像局部区域上做加权求和

卷积核继续向右或向下滑动, 就得到下一个位置的输出。所有位置的输出组成新的特征图。

模型	连接方式	对图像结构的利用
MLP	常把图像展平成向量, 全连接	容易弱化二维空间结构
CNN	局部连接, 卷积核滑动	直接利用局部关联


3.5 Zero Padding

页码: p14

Padding 是在图像边缘补值, 常见是补 0。作用是控制卷积后图像大小, 避免图像尺寸过快变小。

3.5.1 Padding 示意

Zero Padding——解决图像过卷积后大小改变的问题



[1] 《深度学习现象导论》许志钦、张耀宇 https://github.com/xuzhiqin1990/understanding_dl



3.6 Stride


页码: p15

Stride 是卷积核滑动步长。课件用 $\text{stride}(i, j)$ 表示横向跨 i 步、纵向跨 j 步。

3.6.1 Stride 示意

跨步 $\text{stride}(i, j)$

横向跨 i 步, 纵向跨 j 步。图中第一行为 $\text{stride}(1,1)$, 第二行为 $\text{stride}(2,2)$



[1] 《深度学习现象导论》许志钦、张耀宇 https://github.com/xuzhiqin1990/understanding_dl



Figure 3: p15 $\text{stride}(1,1)$ 和 $\text{stride}(2,2)$ 的滑动差别

输入长度方向位置:

1 2 3 4 5

卷积核大小 = 3

$\text{stride} = 1$ 时:

[1 2 3], [2 3 4], [3 4 5]

输出长度 = 3

$\text{stride} = 2$ 时:

[1 2 3], [3 4 5]

输出长度 = 2

3.7 多通道卷积

页码: p16

RGB 图像有 3 个输入通道。多通道卷积中, 一个完整卷积核需要覆盖所有输入通道。


3.7.1 多通道卷积示意

RGB 输入图像有 3 个通道:

R 通道局部区域 $\rightarrow$ 与卷积核 R 部分相乘求和

G 通道局部区域 $\rightarrow$ 与卷积核 G 部分相乘求和

多通道卷积



[1] 《深度学习现象导论》 许志钦、张耀宇 https://github.com/xuzhiqin1990/understanding_dl



Figure 4: p16 多通道卷积示意

B 通道局部区域 -> 与卷积核 B 部分相乘求和

三个通道结果相加，再加 bias
= 这个卷积核在当前位置的输出

一个卷积核产生一个输出通道：

输入：32 x 32 x 3

一个卷积核大小：5 x 5 x 3

卷积核个数：6

输出：空间大小另算，通道数 = 6

3.8 卷积层尺寸计算总结

页码：p14-p16

卷积层的计算可以分成三件事：空间大小怎么变，通道数怎么变，参数量怎么算。

3.8.1 输入、卷积核和输出的形状

输入：H x W x C_{in}

一个卷积核：K x K x C_{in}

卷积核个数：C_{out}

输出：H_{out} x W_{out} x C_{out}

其中：

- H, W: 输入图像或特征图的高和宽。
- C_{in}: 输入通道数。
- K: 卷积核大小，例如 3 x 3 卷积核中 K = 3。
- C_{out}: 卷积核个数，也就是输出通道数。

- H_{out} , W_{out} : 输出特征图的高和宽。

3.8.2 输出空间尺寸公式

$$H_{out} = \text{floor}((H + 2P - K) / S) + 1$$

$$W_{out} = \text{floor}((W + 2P - K) / S) + 1$$

其中:

- P 是 padding 大小。
- S 是 stride 大小。
- floor 表示向下取整。

3.8.3 padding 和 stride 的影响

参数	增大后通常会怎样	直观理解
padding	输出空间尺寸变大	边缘补了一圈, 能滑动的位置更多
stride	输出空间尺寸变小	卷积核跳得更远, 采样位置更少
卷积核大小	输出空间尺寸变小	窗口更大, 可放置的位置更少
卷积核个数	输出通道数变多	一个卷积核产生一个输出通道

3.8.4 参数量计算

卷积层通常有 bias。每个卷积核产生一个输出通道, 因此每个输出通道对应 1 个 bias。

不考虑 bias:

$$\text{参数量} = K \times K \times C_{in} \times C_{out}$$

考虑 bias:

$$\text{参数量} = K \times K \times C_{in} \times C_{out} + C_{out}$$

例子:

输入通道数 $C_{in} = 3$

卷积核大小 $K = 5$

卷积核个数 $C_{out} = 6$

不考虑 bias: $5 \times 5 \times 3 \times 6 = 450$

考虑 bias: $5 \times 5 \times 3 \times 6 + 6 = 456$

3.8.5 例子 1: padding 保持大小

输入: $32 \times 32 \times 3$

卷积核: 3×3

卷积核个数: 16

padding: 1

stride: 1

$$H_{out} = (32 + 2 \times 1 - 3) / 1 + 1 = 32$$

$$W_{out} = 32$$

$$C_{out} = 16$$

输出: $32 \times 32 \times 16$

3.8.6 例子 2: stride 让尺寸减小

输入: $32 \times 32 \times 3$

卷积核: 3×3

卷积核个数: 16

padding: 1

stride: 2

$H_{out} = \text{floor}((32 + 2 \times 1 - 3) / 2) + 1$

$= \text{floor}(31 / 2) + 1$

$= 16$

$W_{out} = 16$

$C_{out} = 16$

输出: $16 \times 16 \times 16$

3.9 池化 Pooling

页码: p18

池化层用于对局部区域做汇总。常见池化包括最大池化和平均池化。

池化方式	操作
最大池化	取局部窗口中的最大值
平均池化	取局部窗口中的平均值

3.9.1 池化示意

局部区域:

1 3

2 4

最大池化: 取最大值 4

平均池化: 取平均值 $(1+3+2+4)/4 = 2.5$

尺寸例子:

输入: $32 \times 32 \times 16$

最大池化窗口: 2×2

stride: 2

输出: $16 \times 16 \times 16$

3.10 CNN 整体结构与层的组合

页码: p20-p22

p20 给出了一个典型 CNN 结构:

输入 RGB 三通道图像

-> 卷积 + ReLU + 池化

-> 卷积 + ReLU + 池化

-> 展平

-> 全连接

-> Softmax 输出类别概率

经典 LeNet 可作为类似结构的例子:

输入图像 -> 卷积 -> 池化 -> 卷积 -> 池化 -> 展平 -> 全连接 -> 输出

需要注意: CNN 没有唯一固定的网络格式。卷积层、激活函数、池化层、全连接层等都可以按任务需要组合。

常见组合方式:

卷积 -> 激活 -> 卷积 -> 激活 -> 池化
卷积 -> 激活 -> 池化 -> 卷积 -> 激活 -> 池化
卷积 -> 激活 -> 展平 -> 全连接 -> 输出

只要前一层的输出形状能作为后一层的输入，这些层就可以灵活搭配。不同 CNN 结构的差别，往往就体现在层的数量、顺序、卷积核个数、是否使用池化等设计上。

3.11 关键记忆

- 图像具有局部关联性和一定不变性；CNN 的设计正是为了利用这些图像特征。p3-p6
- 指数衰减下降较快，幂级数衰减下降较慢；幂级数衰减可以看作许多指数衰减成分的叠加。p3-p5
- 类视皮层设计启发 CNN：先提取局部简单特征，再逐步整合成复杂信息。p7-p10
- 卷积的核心是局部窗口加权求和；CNN 相比 MLP 的重要特点是局部连接和参数共享。p11-p13
- Padding 在边缘补值，用来控制输出空间大小；padding 越大，输出空间尺寸通常越大。p14
- Stride 是卷积核滑动步长；stride 越大，输出空间尺寸通常越小。p15
- 多通道卷积中，一个完整卷积核覆盖所有输入通道；一个卷积核产生一个输出通道。p16
- 卷积输出空间尺寸看 H, W, K, P, S；输出通道数看卷积核个数 C_out。p14-p16
- 卷积参数量看 K, C_in, C_out；有 bias 时再加 C_out，不要乘 H_out 和 W_out。p14-p16
- 池化汇总局部信息，降低空间尺寸，通常没有可学习参数，也通常不改变通道数。p18
- CNN 没有唯一固定格式；卷积、激活、池化、展平、全连接、softmax 等模块可以灵活组合，但相邻层的输入输出尺寸必须匹配。p20-p22

3.12 思考题

1. 判断：池化操作一定只能由专门的池化层实现，不能用卷积实现类似效果。
答案：错误。例如使用带 stride 的卷积可以在提取特征的同时降低空间尺寸，起到类似下采样的作用。
2. 判断：池化操作可以和卷积操作在同一层的设计中部分合并，例如用 stride 大于 1 的卷积完成下采样。
答案：正确。
3. 填空：1 x 1 卷积核不改变单个位置的空间邻域大小，但可以改变 _____ 数。
答案：通道。
4. 计算：输入为 32 x 32 x 3，卷积核为 3 x 3，padding=1，stride=1，卷积核个数为 16，输出尺寸是 _____。
答案：32 x 32 x 16。
5. 计算：一个卷积层中 K=5，C_in=3，C_out=6，且每个卷积核有 bias，参数量是 _____。
答案：5 x 5 x 3 x 6 + 6 = 456。

4 循环神经网络 RNN 与 LSTM

这一章按 PDF 顺序复习：语言任务特点 -> 数据准备 -> 词元化 -> one-hot 与 embedding -> next token prediction -> RNN 设计 -> BPTT -> LSTM。重点是让学生理解：文本是可变长度序列，RNN 为什么适合处理序列，以及 LSTM 的门控机制解决了什么问题。

4.1 自然语言处理 NLP 的任务特点

页码：p3-p5

NLP 的目标是让计算机理解、生成和处理自然语言。常见任务包括机器翻译、文本分类、语音识别、信息检索、智能客服等。

自然语言有层次结构、语法结构、上下文相关性和长程依赖。更重要的是，文本天然是可变长度的离散符号序列。

4.1.1 文本数据的可变长度

不同句子的 token 数可能不同：

我喜欢 AI
我非常喜欢人工智能这门课
这部电影虽然节奏很慢，但是后半段非常精彩

自然语言处理的特点：

- 复杂的层次结构：词根构成单词，单词构成短语，短语构成句子，句子构成段落...
- 严格的语法结构：主语，谓语，宾语
- 递归性：名词从句可以充当另一个句子的主语、宾语或表语。ex: 他说他昨天工作到很晚
- 语言是离散的符号序列，而不是连续的像素值
- 语言具有长程依赖关系
- 语言具有上下文相关性：我爱上海的交通大学，不爱上海的交通
- 传统模型的局限性：全连接卷积网络输入固定，对历史输入无记忆

常见基础语言模型：

- 循环神经网络（传统RNN，LSTM）
- Transformer

Figure 5: p5 自然语言处理的特点

这和图像任务很不一样。图像通常可以统一 resize 成固定大小，例如 $32 \times 32 \times 3$ ；文本句子却天然长短不一，并且词语顺序会影响含义。

4.1.2 MLP、CNN 与 RNN 的区别

模型	输入特点	是否天然适合可变长度序列
MLP	常需要固定长度向量	不适合
CNN	擅长局部窗口特征	不天然适合
RNN	逐 token 处理序列	适合

RNN 能处理可变长度文本的原因是：它不是一次性要求输入固定长度向量，而是按时间步逐个读入 token，并把已经读过的信息压缩到隐藏状态中。

短句：x1 → x2 → x3

长句：x1 → x2 → x3 → x4 → x5 → ...

同一个 RNN 单元可以在不同时间步重复使用。

4.2 数据准备

页码：p6-p7

数据准备是语言模型训练的基础。考试不考复杂数据工程流程，但要知道文本数据进入模型前通常需要清洗和处理。

步骤	作用
数据收集	获得足够数量的文本
质量过滤	去掉质量很差、无意义或噪声很大的文本
敏感内容过滤	减少有毒内容、隐私信息等风险

步骤	作用
数据去重	减少重复样本，避免模型过度记忆重复文本
词元化	把文本切成 token
向量化	把 token 变成神经网络能处理的数值向量

关键理解：数据不是直接进入 RNN。文本通常要先经过清洗、切分和向量化，才能变成神经网络输入。

4.3 分词、one-hot 与 embedding

页码：p8-p11

文本进入神经网络通常要经过两步：

文本 -> tokenization -> token 序列 -> one-hot 或 embedding 向量

4.3.1 Tokenization 词元化

Tokenization 是把文本切成 token。Token 可以是词、子词、字符或特殊符号。

自然语言处理：词元化（分词）



词元化：将属于同一个语义或语法单元的字符聚合在一起

- 基于规则的分词：使用一些预定义的规则来切分文本，如根据空格或标点符号进行切分
- 基于统计的分词：统计语言中单词或子词的频率，来决定切分的边界

ex:

"Transformer is a powerful tool for natural language processing."

基于规则：["Transformer", "is", "a", "powerful", "tool", "for", "natural", "language", "processing", "."]

基于统计：["Trans", "former", "is", "a", "power", "ful", "tool", "for", "natural", "language", "process", "ing", "."]

常用词元化方法：BPE (Byte Pair Encoding , 字节对编码) 分词^[1], WordPiece分词^[2], Unigram分词^[3]

特殊符号：用来表示一些特殊的语义或结构

- CLS：表示句子的开始，通常用于分类任务中作为整个句子的表示。
- SEP：表示句子的结束，或者在多句输入的情况下，用于分隔不同的句子。
- MASK：表示被掩盖的单词，用于训练过程中的掩码语言模型 (Masked Language Model, MLM)任务。
- PAD：表示填充符号，用于将不同长度的句子补齐到相同长度。
- UNK：表示未登录词，即那些在训练集中没有出现过的词。

[1] Philip Gage. "A new algorithm for data compression". In: C Users Journal (1994).

[2] Hugging Face. "WordPiece tokenization - Hugging Face NLP Course.", <https://huggingface.co/learn/nlp-course/chapter6/6>.

[3] Hugging Face. "Unigram tokenization - Hugging Face NLP Course.", <https://huggingface.co/learn/nlp-course/chapter6/7>.



Figure 6: p8 词元化示意

词元化可以基于规则，也可以基于统计。BPE、WordPiece、Unigram 都是常见方法。

原始句子：

Transformer is a powerful tool for natural language processing.

基于规则：

[Transformer, is, a, powerful, tool, for, natural, language, processing, .]

基于统计：

[Trans, former, is, a, power, ful, tool, for, natural, language, process, ing, .]

常见特殊符号：

特殊符号	含义
CLS	句子开始，常用于分类任务
SEP	句子结束，或分隔不同句子
MASK	被遮盖的 token
PAD	填充符号，用于补齐不同长度
UNK	未登录词，表示词表中没有出现过的词

4.3.2 one-hot 与 embedding

One-hot 用一个很长的向量表示词表中的一个 token，向量中只有一个位置是 1，其余位置是 0。


Embedding 把 token 映射成低维稠密向量。Embedding 矩阵是可训练参数，可以在训练中学习词语之间的关系。

独热编码和嵌入

输入表示：将原始的符号化数据转换成可供处理的数值向量。

● 原则

- 等价性
 - 对任何词没有先验偏置
 - 任何一对词语的先验距离相同
- 可学习性：不同词语间的关系应取决于广义语境
 - $\text{Dist}(\text{study}, \text{learn}) < \text{Dist}(\text{study}, \text{play})$ ($\text{dist}(\cdot, \cdot)$ 表示距离函数)
 - 1,2,3,4,5,6,7 应该按顺序排列



图一：词嵌入示意图

● 方法

- 独热编码(One-hot embedding): 用 $\varepsilon_i \in \mathbb{R}^N$ 表示词表中的每个向量， N 表示词表中词的数量， ε_i 表示第 i 个元素不为 0 的单位向量。
- 词嵌入(word embedding): $x_i = W^{emb} \varepsilon_i \in \mathbb{R}^N$, $W^{emb} \in \mathbb{R}^{d \times N}$ 是可训练的嵌入矩阵。

[1] https://pytorch.org/tutorials/intermediate/char_rnn_classification_tutorial.html



Figure 7: p10 one-hot 与词嵌入示意

表示方式	特点	记忆
one-hot	高维、稀疏	不表达词义相似性
embedding	低维、稠密、可训练	可以学习语义关系

Embedding 的计算可以理解为查表：

第 i 个 token 的 one-hot 向量: epsilon_i

embedding 向量: $x_i = W_{\text{emb}} \text{epsilon}_i$

4.4 Next Token Prediction

页码: p13-p16

Next Token Prediction 是根据已有前文预测下一个 token。它是现代语言模型常用的训练框架。

输入：我 喜欢 人工

目标：智能

大量文本都可以转化为“预测下一个 token”的任务。它的好处是：不需要人工为每句话单独标标签，只要有文本，就可以构造训练信号。

训练：每个位置预测下一个 token

推理：生成一个 token 后，把它接到上下文后继续生成

4.5 RNN 的设计

页码：p17-p18

RNN 是循环神经网络，适合处理序列数据。它的核心设计是：当前隐藏状态不仅看当前输入，也看上一时刻隐藏状态。

循环神经网络 (Recurrent Neural Networks)




图 3.19: 循环神经网络的基本结构

如图3.19所示, 这是一个基本的循环神经网络单元, 下面我们详细介绍一下这个单元是如何工作的。我们的输入为时序序列 $x_1, x_2, \dots, x_{t-1}, x_t, x_{t+1}, \dots, x_n$, 并通过公式(3.15), (3.16)和(3.17)的方式计算得到对应的输出序列 $o_1, o_2, \dots, o_{t-1}, o_t, o_{t+1}, \dots, o_n$ 。

$$S_0 = 0, \quad (3.15)$$

$$S_t = f(\mathbf{U} \cdot x_t + \mathbf{W} \cdot S_{t-1} + b), \quad t = 1, 2, 3, \dots, n, \quad (3.16)$$

$$o_t = g(\mathbf{V} \cdot S_t) \quad (3.17)$$

其中 f 是激活函数, 通常使用 Tanh 函数, $g = \text{Softmax}(x)$ 是 softmax 函数。 S_t 是状态记忆, $\mathbf{U}$, $\mathbf{W}$, $\mathbf{V}$ 和 b 分别是输入权重矩阵、循环权重矩阵、输出权重矩阵和偏置项。



Figure 8: p18 RNN 基本结构与公式

RNN 的隐藏状态可以理解为“目前为止读过内容的压缩记忆”。序列长度不同也没关系，因为 RNN 可以重复使用同一个计算单元，按时间步逐个处理输入。

考试要会识别 RNN 的基本公式：

$$S_0 = 0$$

$$S_t = f(\mathbf{U} x_t + \mathbf{W} S_{t-1} + b)$$

$$o_t = g(\mathbf{V} S_t)$$

其中：

- x_t : 第 t 个输入。
- S_t : 第 t 步隐藏状态。
- S_{t-1} : 上一时刻隐藏状态。
- o_t : 第 t 步输出。
- $\mathbf{U}$, $\mathbf{W}$, $\mathbf{V}$, b : 可训练参数。
- f 常用 tanh, g 可以是 softmax。

为什么能处理可变长度？

输入一个 token，更新一次隐藏状态；

输入多少个 token，就重复多少次；
参数 U 、 W 、 V 在不同时间步共享。

Encoder-Decoder RNN 可以处理输入输出长度不同的任务，例如机器翻译。

4.6 BPTT 与梯度问题

页码：p20

BPTT 是 BackPropagation Through Time，意思是随时间反向传播。训练 RNN 时，误差要沿多个时间步向前传播回去。

BPTT 算法训练循环神经网络



随时间反向传播 BPTT (BackPropagation Through Time, BPTT)： o_t 的计算涉及到前 $t-1$ 步的信息，计算梯度时也会涉及到多个时间步

$$\begin{aligned} S_0 &= 0, \\ S_t &= f(U \cdot x_t + W \cdot S_{t-1} + b), \quad t = 1, 2, 3, \dots, n, \\ o_t &= g(V \cdot S_t) \end{aligned}$$

考虑 Loss 对参数 W 的导数：
链式法则：Loss 对 S_t 对导，
 S_t 依赖于 S_{t-1} ， S_{t-1} 依赖于 W
 S_{t-1} 依赖于 S_{t-2} ， S_{t-2} 依赖于 W
.....

梯度要经过多个时间步的链式计算，导致**梯度消失和梯度爆炸**，太长程的记忆不容易学习



Figure 9: p20 BPTT 与梯度问题

普通反向传播：沿网络层反向传播

BPTT：沿时间展开后的网络反向传播

长序列中，梯度需要经过很多次链式相乘，容易出现两个问题：

问题	含义	影响
梯度消失	梯度越来越小	较早时间步的信息难以学习
梯度爆炸	梯度越来越大	训练不稳定

因此，普通 RNN 对长程依赖的建模能力有限。

4.7 LSTM

页码：p21-p25

LSTM 是 Long Short-Term Memory，长短期记忆网络。它在 RNN 基础上引入记忆状态，并通过门控机制控制信息流动。

长短期记忆网络 (Long short-term memory, LSTM)

基本原则：1) 任何信息使用前先做线性变换,权重可学
2) 控制比例的称为“门”，激活用Sigmoid
3) 提取信息的运算，激活用Tanh




图 3.21: 单个门控神经元主要部件和并行隐藏状态示意图

门控神经元-遗忘门

保留的比例 $f_t = \sigma(W_{Sf}S_t + W_{xf}x_{t+1} + b_f)$

门控神经元-输入门

写入的比例 $i_t = \sigma(W_{Si}S_t + W_{xi}x_{t+1} + b_i)$

新的知识 $\tilde{C}_{t+1} = \tanh(W_{SC}S_t + W_{xC}x_{t+1} + b_C)$

新的记忆状态 $C_{t+1} = f_t * C_t + i_t * \tilde{C}_{t+1}$

门控神经元-输出门

输出的比例 $o_t = \sigma(W_{So}S_t + W_{xo}x_{t+1} + b_o)$

输出 $y_{t+1} = S_{t+1} = o_t * \tanh(C_{t+1})$

为什么能称为“遗忘门”、“输入门”、“输出门”、“知识”？
这是一种形象类比，没有严格证明。



Figure 10: p24 LSTM 门控机制

结构	作用
记忆状态	保存较长期的信息
遗忘门	控制保留多少旧记忆
输入门	控制写入多少新信息
输出门	控制输出多少记忆信息

门通常使用 sigmoid，因为 sigmoid 输出在 0 到 1 之间，适合表示“保留多少”“写入多少”这种比例。候选记忆常用 tanh 提取。

LSTM 设计里最重要的点：

1. 多了一条记忆状态 C_t ，用于保存较长期信息。
2. 用门控制比例，而不是简单地全保留或全丢弃。
3. 遗忘门决定旧记忆保留多少。
4. 输入门决定新信息写入多少。
5. 输出门决定当前输出多少记忆信息。

LSTM 不能保证完全消除所有梯度问题，但它可以缓解普通 RNN 的长程依赖和梯度消失问题。

4.8 关键记忆

- NLP 处理的是离散符号序列，词语顺序和上下文都很重要。
- 文本数据通常是可变长度的；MLP/CNN 不天然适合记忆历史信息，RNN 通过隐藏状态逐步处理序列。
- 文本进入神经网络前通常要经过数据清洗、tokenization 和向量化。
- Tokenization 是把文本切成 token；token 可以是词、子词、字符或特殊符号。
- One-hot 高维稀疏，本身不表达词义相似性；embedding 低维稠密，可以通过训练学习语义关系。
- Next Token Prediction 是根据前文预测下一个 token，是现代语言模型常用训练框架。
- RNN 的当前隐藏状态依赖当前输入和上一时刻隐藏状态，公式为 $S_t = f(U x_t + W S_{t-1} + b)$ 。
- BPTT 是随时间反向传播；长序列中容易出现梯度消失或梯度爆炸。
- LSTM 通过记忆状态和门控机制控制信息保留、写入和输出，可以缓解长程依赖问题。

4.9 思考题

1. 判断：文本数据通常是可变长度序列，因此普通 MLP 不天然适合直接处理任意长度文本。
答案：正确。
2. 填空：把文本切成 token 的过程叫做 _____。
答案：tokenization 或词元化。
3. 填空：RNN 的基本公式中，当前隐藏状态可以写成 $S_t = f(U x_t + W ______ + b)$ 。
答案： S_{t-1} 。
4. 判断：RNN 可以处理可变长度序列，一个重要原因是同一个 RNN 单元可以在不同时间步重复使用。
答案：正确。
5. 选择：LSTM 中控制保留多少旧记忆的是：A. 输入门 B. 遗忘门 C. 输出门 D. Softmax。
答案：B。

5 Transformer

这一章按“为什么需要 Transformer -> embedding 与位置编码 -> 注意力机制 -> Q/K/V -> causal mask -> Transformer block 与输出”的顺序复习。重点是理解 Transformer 如何用注意力机制建模 token 之间的关系。

5.1 为什么需要 Transformer

Transformer 出现前，序列任务常用 RNN 和 LSTM。RNN/LSTM 能处理序列，但有两个明显限制：

问题	含义
长程依赖困难 并行计算不方便	很远位置的信息不容易传到当前时刻 RNN 通常按时间步顺序计算

Transformer 使用注意力机制直接建模 token 之间的关系，更容易捕捉全局语义关系，也更适合并行计算。

5.2 Embedding 与位置编码

Token 是离散符号，进入神经网络前需要先变成向量。

token -> embedding 向量

但仅有 embedding 还不够。同一个 token 出现在不同位置时，句子含义可能不同，因此模型还需要位置信息。

输入表示 = token embedding + 位置编码

位置编码用于告诉模型 token 在序列中的位置。位置编码可以是可学习的，也可以是人为设计的。

5.3 注意力机制直观理解

注意力机制可以分成两步：

第一步：算“我应该关注谁”

第二步：按关注程度汇总信息

对某个 token 来说，模型会先计算它和其他 token 的关联强度，再把这些关联强度变成权重，对其他 token 的信息加权求和。

概念	含义
注意力分数	token 之间的关联强度
Softmax	把分数变成权重
注意力权重	通常非负，总和为 1
加权求和	按关注程度汇总信息

注意力权重越大，说明该位置对当前 token 的更新影响越大。

5.4 Q、K、V

注意力机制中常见三个向量：Q、K、V。

符号	英文	作用
Q	Query	当前 token 发出的查询
K	Key	其他 token 可被匹配的键
V	Value	真正被汇总的信息内容

Q、K、V 都由输入向量经过可训练线性变换得到。Q 和 K 用来计算相关性，V 用来做加权求和。

Q 和 K → 算关联强度

Softmax → 得到注意力权重

注意力权重 和 V → 加权求和

5.5 Causal Mask

在生成任务中，模型预测当前位置时不能看到未来 token，否则就等于提前看到了答案。

已知：我 喜欢

预测：人工

不能偷看：智能

Decoder 使用 causal mask 遮住未来位置。常见做法是把未来位置的注意力分数设为负无穷，经过 Softmax 后，这些位置的权重接近 0。

Causal mask 保证 next token prediction 的因果性：预测当前位置时只能看当前位置和前文，不能看未来。

5.6 Transformer Block、FNN 与输出

一个 Transformer block 通常包含注意力模块和前馈网络 FNN，并配合残差连接和 LayerNorm。

输入

→ 注意力模块

→ 残差连接 + LayerNorm

→ FNN

→ 残差连接 + LayerNorm

→ 输出

FNN 是前馈全连接网络，对每个 token 分别作用。多个 Transformer block 可以复制堆叠，形成深层 Transformer。

输出层把隐藏向量映射到词表大小，再经过 Softmax 得到下一个 token 的概率分布。

解码方式	含义	结果是否固定
贪婪解码	每步取概率最大的 token	通常固定
采样解码	按概率分布随机抽样	可能不同

5.7 关键记忆

- Transformer 的核心思想之一是注意力机制，用来建模 token 之间的关系。
- Transformer 仍然需要位置信息；位置编码用于表示 token 在序列中的位置。
- 注意力机制先计算关联强度，再用 Softmax 得到权重，最后对信息加权求和。
- Q 和 K 用于计算相关性，V 是真正被汇总的信息内容。
- Decoder 做 next token prediction 时不能看到未来 token，需要 causal mask。
- Transformer block 通常由注意力模块、FNN、残差连接和 LayerNorm 等部分组成。
- 输出层维度通常对应词表大小；Softmax 把输出转成下一个 token 的概率分布。
- 采样解码具有随机性，同一输入可能生成不同结果。

5.8 思考题

1. 判断：Transformer 使用注意力机制来建模 token 之间的关系。
答案：正确。
2. 填空：Transformer 需要加入 _____，用来表示 token 在序列中的位置。
答案：位置编码。
3. 选择：Q、K、V 中，用来真正汇总信息内容的是：A. Q B. K C. V D. mask。
答案：C。
4. 判断：Decoder 做 next token prediction 时，可以看到未来 token。
答案：错误。需要 causal mask 遮住未来位置。
5. 判断：采样解码按概率分布随机抽样，因此同一输入可能生成不同结果。
答案：正确。

6 神经网络训练现象：频率原则

这一章不适合考复杂推导，重点考概念和直觉。

6.1 过参数化与隐式偏好

复习重点：

1. 过参数化指模型参数量大于样本量或明显很大。
2. 过参数化模型理论上容易表达很多复杂函数。
3. 但神经网络实际训练中常常仍能泛化较好。
4. 训练误差为 0 的解可能有很多。
5. 神经网络训练过程会倾向某些解，这叫隐式偏好。

易错点：

1. “过参数化神经网络一定严重过拟合。”错误。
2. “训练过程可能偏向某类解。”正确。
3. “隐式偏好一定写在损失函数公式里。”错误。

6.2 频率、低频与高频

复习重点：

1. 频率描述函数变化的快慢。
2. 低频对应平滑、轮廓、整体趋势。
3. 高频对应振荡、细节、快速变化。
4. 图像中低频常对应大轮廓，高频常对应边缘、纹理或噪声。
5. 高频不一定没用，但更容易包含噪声。

易错点：

1. “低频通常更平滑。”正确。
2. “高频永远没有用。”错误。
3. “细节和噪声都可能表现为高频。”正确。

6.3 频率原则

复习重点：

1. 频率原则也叫 spectral bias。
2. 神经网络训练通常先拟合低频，再拟合高频。
3. 在一维函数中表现为先学平滑轮廓，再学振荡细节。
4. 在图像拟合中表现为先学整体轮廓，再学局部细节。
5. 频率原则可以帮助解释为什么一些神经网络不容易立即拟合噪声。

必背句：

频率原则：神经网络在训练过程中通常按照从低频到高频的顺序拟合目标函数。

易错点：

1. “频率原则说神经网络通常先学高频噪声。”错误。
2. “频率原则和泛化有关系。”正确。
3. “频率原则只适用于分类任务，不能用于函数拟合直觉。”错误。

6.4 早停 Early stopping

复习重点：

1. 数据中可能有噪声。
2. 低频成分通常先被模型学习。
3. 高频噪声往往在训练后期被逐渐拟合。
4. 早停是在模型过度拟合噪声前停止训练。
5. 早停有助于提高测试集泛化能力。

易错点：

1. “训练越久，测试误差一定越低。”错误。
2. “早停可能防止拟合高频噪声。”正确。
3. “早停就是让模型完全不训练。”错误。

6.5 思考题

1. 填空：频率原则也叫 spectral _____。
答案：bias。
2. 判断：神经网络训练通常先拟合低频成分，再拟合高频成分。
答案：正确。
3. 选择：图像中的边缘、纹理、噪声通常更接近：A. 低频 B. 高频 C. 标签 D. bias。
答案：B。
4. 判断：过参数化神经网络一定会严重过拟合，因此不可能泛化好。
答案：错误。
5. 判断：早停可以理解为在模型进一步拟合高频噪声前停止训练。
答案：正确。

7 参数凝聚与解的平坦性

7.1 初始化大小的影响

复习重点：

1. 初始化是训练开始前给参数赋初值。
2. 初始化会影响训练过程和最终结果。
3. 初始化太大时，网络输出可能更随机、更复杂，更容易过拟合。
4. 初始化较小时，网络输出可能更平滑。
5. 常见初始化包括 LeCun、Xavier、Kaiming。
6. 模型越大时，初始化尺度通常需要更谨慎。
7. 所有参数不能简单初始化为 0，因为会破坏训练中的对称性打破。

易错点：

1. “初始化对训练结果没有任何影响。”错误。
2. “所有参数初始化为 0 是最安全的做法。”错误。
3. “初始化大小会影响训练。”正确。

7.2 参数凝聚

复习重点：

1. 参数凝聚指小初始化下，同层神经元会有趋同的偏好。
2. 多个相似神经元可以等效为较少的有效神经元。
3. 凝聚使大网络在表达上像复杂度更低的小网络。
4. 过参数化大网络发生凝聚后，仍然比直接训练小网络更容易优化。
5. 凝聚可理解为一种复杂度控制。

必背句：

参数凝聚：小初始化下，同层神经元会出现趋同的偏好，多个神经元可能等效为较少的有效神经元。

易错点：

1. “参数凝聚通常与小初始化有关。”正确。
2. “凝聚意味着网络完全不能训练。”错误。
3. “凝聚可以看作降低有效复杂度的一种现象。”正确。

7.3 平坦解与尖锐解

复习重点：

1. 平坦解指参数附近一片区域损失都较低。
2. 尖锐解指参数稍微改变，损失就明显上升。
3. 训练集和测试集常有噪声，平坦解对扰动更鲁棒。
4. 平坦解通常泛化更好。
5. 小批量训练倾向于找到更平坦的解。
6. 合理较大的学习率也可能帮助找到更平坦的解。
7. Dropout 也可能有助于提升解的平坦性。

易错点：

1. “平坦解对参数扰动更鲁棒。”正确。
2. “尖锐解一定比平坦解泛化更好。”错误。
3. “小批量训练可能帮助找到更平坦的解。”正确。

7.4 思考题

1. 判断：初始化大小会影响神经网络的训练过程和最终结果。
答案：正确。
2. 判断：所有参数初始化为 0 通常不是好做法，因为会破坏对称性打破。
答案：正确。
3. 填空：小初始化下，同层神经元可能出现趋同偏好，这种现象叫 _____。
答案：参数凝聚。
4. 选择：平坦解通常指：A. 参数附近一片区域损失都较低 B. 参数必须全为 0 C. 训练误差一定为 1 D. 没有梯度。
答案：A。
5. 判断：尖锐解对参数扰动更敏感，泛化通常不如平坦解稳健。
答案：正确。

8 大模型介绍

8.1 什么是大模型

复习重点：

1. 大模型通常也叫基础模型。
2. 大模型参数量很大。
3. 大模型经过大规模数据训练。
4. 大模型可以适应多种下游任务。
5. 大语言模型是最早展现出通用智能特征的大模型之一。

6. 许多模态的数据也可以类似语言一样进行 token 化。

易错点：

1. “大模型通常经过大规模数据训练。”正确。
2. “大模型只能做一个固定任务。”错误。
3. “基础模型可以适应多种下游任务。”正确。

8.2 Encoder、Decoder 与常见架构

复习重点：

1. Encoder 可以看到上下文所有 token。
2. Decoder 只能看到当前位置和前文 token。
3. Encoder-only 常用于理解任务。
4. Decoder-only 常用于生成任务。
5. Encoder-Decoder 常用于输入和输出都需要建模的任务，如翻译。
6. BERT 是 Encoder-only 的代表。
7. GPT、Llama、DeepSeek 等是 Decoder-only 的代表。
8. BART、T5 是 Encoder-Decoder 的代表。
9. 当前主流生成式大语言模型多采用 Decoder-only。

对照表：

架构	是否看未来	常见任务	代表
Encoder-only	可以看双向上下文	理解任务	BERT
Decoder-only	只能看当前和前文	生成任务	GPT/Llama/DeepSeek
Encoder-Decoder	编码输入，解码输出	翻译等	T5/BART

易错点：

1. “Decoder-only 在生成任务中很常见。”正确。
2. “Encoder-only 非常适合直接做 next token prediction。”通常不适合。
3. “BERT 是 Decoder-only。”错误。

8.3 预训练、微调、提示词、蒸馏

复习重点：

1. 预训练是在大规模数据上训练基础能力。
2. 语言模型预训练常用 next token prediction。
3. 微调是在预训练模型基础上，用特定任务数据继续训练。
4. 强化学习后训练可增强推理能力，也可用于对齐人类偏好。
5. 提示词工程通过设计输入让模型给出更好的回答。
6. 知识蒸馏把大模型能力迁移到小模型中。
7. Teacher model 是提供知识的大模型或强模型。
8. Student model 是接受蒸馏的小模型或目标模型。

易错点：

1. “预训练通常需要大量数据。”正确。
2. “提示词工程一定会更新模型参数。”错误。
3. “知识蒸馏可以让小模型学习大模型输出中的知识。”正确。

8.4 大模型中的现象

复习重点：

1. Scaling law 描述模型规模、数据量、计算量和测试损失之间的规律关系。

2. 一般来说，在一定范围内，规模、数据、算力增加会带来性能提升。
3. 上下文学习指模型不更新参数，仅通过任务描述和示例适应任务。
4. 思维链是让模型生成中间推理步骤。
5. 思维链可提升复杂推理任务表现。
6. 幻觉是模型生成看似真实但实际错误或误导的信息。
7. 大模型可能包含偏见。

易错点：

1. “上下文学习不需要更新模型权重。”正确。
2. “思维链就是引导模型写出中间推理步骤。”正确。
3. “大模型永远不会产生幻觉。”错误。
4. “大模型可能带有偏见。”正确。

8.5 思考题

1. 判断：大模型通常经过大规模数据训练，可以适应多种下游任务。
答案：正确。
2. 选择：当前主流生成式大语言模型多采用：A. Encoder-only B. Decoder-only C. 纯 CNN D. 纯 RNN。
答案：B。
3. 填空：预训练是在大规模数据上训练模型的 _____ 能力。
答案：基础。
4. 判断：上下文学习通常不更新模型参数，而是通过任务描述和示例让模型适应任务。
答案：正确。
5. 判断：幻觉指模型生成看似真实但实际错误或误导的信息。
答案：正确。

9 强化学习

这一章是考试重点，但不建议考复杂推导。重点是概念、关系和最简单公式。

9.1 强化学习是什么

复习重点：

1. 强化学习是决策型任务。
2. 智能体在环境中采取动作。
3. 环境返回奖励和新的状态。
4. 智能体通过反复试错学习。
5. 目标是最大化期望累计奖励。
6. 奖励可以是正的，也可以是负的。
7. 强化学习不同于监督学习：通常没有每一步的正确标签，而是通过奖励反馈学习。

基本循环：

状态 s_t $\rightarrow$ 智能体选择动作 a_t $\rightarrow$ 环境给出奖励 r_{t+1} 和下一状态 s_{t+1}

易错点：

1. “强化学习只做静态分类任务。”错误。
2. “强化学习强调智能体和环境交互。”正确。
3. “奖励只能是正数。”错误。

9.2 状态、观察、动作空间、奖励

复习重点：

1. 状态 State 是环境完整信息。
2. 观察 Observation 是智能体实际看到的信息。

3. 完全可观测环境中，观察和状态一致。
4. 部分可观测环境中，观察只是状态的一部分。
5. 动作空间是所有可选动作的集合。
6. 动作空间可以是离散的，也可以是连续的。
7. 棋类、超级马里奥常可看作离散动作空间。
8. 自动驾驶中的方向盘角度、油门等常可看作连续动作空间。
9. 奖励是评价动作好坏的反馈信号。

易错点：

1. “观察一定等于完整状态。”错误。
2. “动作空间可以是离散的，也可以是连续的。”正确。
3. “奖励用于告诉智能体行为好坏。”正确。

9.3 回报与折扣因子

复习重点：

1. 强化学习不只关心当前奖励，还关心未来奖励。
2. 回报是未来奖励的累积。
3. 折扣因子 γ 用于降低远期奖励权重。
4. γ 的取值范围是 $0 \leq \gamma \leq 1$ 。
5. γ 越接近 0，越重视眼前奖励。
6. γ 越接近 1，越重视长期奖励。

无折扣回报：

$$G_t = R_{t+1} + R_{t+2} + R_{t+3} + \dots$$

折扣回报：

$$G_t = R_{t+1} + \gamma R_{t+2} + \gamma^2 R_{t+3} + \dots$$

例题：

未来三个奖励分别为：1, 0, 2

$\gamma = 0.5$

$$\begin{aligned} G_t &= 1 + 0.5 \times 0 + 0.5^2 \times 2 \\ &= 1 + 0 + 0.25 \times 2 \\ &= 1.5 \end{aligned}$$

易错点：

1. “强化学习完全不关心未来奖励。”错误。
2. “折扣因子通常在 0 到 1 之间。”正确。
3. “ γ 越接近 1，越重视长期奖励。”正确。

9.4 情节型任务与连续型任务

复习重点：

1. 情节型任务有起点和终点。
2. 一局游戏、一次棋局、一个关卡通常是情节型任务。
3. 连续型任务没有固定终止状态。
4. 股票交易、交通控制、自动驾驶可看作连续型任务。

易错点：

1. “所有强化学习任务都有明确终点。”错误。
2. “棋类游戏通常可以看作情节型任务。”正确。
3. “连续型任务需要持续决策。”正确。

9.5 探索与利用

复习重点：

1. 探索 Exploration 是尝试未知或不确定动作以获取信息。
2. 利用 Exploitation 是根据已有知识选择当前看起来最好的动作。
3. 只利用可能错过更好的策略。
4. 只探索可能无法获得足够高奖励。
5. 强化学习需要平衡探索和利用。

生活例子：

每天去熟悉但还不错的餐厅：利用
尝试一家没去过的新餐厅：探索

易错点：

1. “探索是尝试未知动作。”正确。
2. “利用是根据已有知识做当前较优选择。”正确。
3. “强化学习中完全不需要探索。”错误。

9.6 策略、价值函数与最优策略

复习重点：

1. 策略 policy 是智能体选择动作的规则。
2. 策略可以是确定性的，也可以是概率性的。
3. 价值函数 $V(s)$ 衡量从状态 s 出发能获得的期望回报。
4. 状态价值高，说明从这个状态出发更有希望获得高累计奖励。
5. 最优策略是在长期意义下使期望累计奖励最大的策略。
6. 最优价值函数和最优策略相互关联。

易错点：

1. “策略就是状态到动作选择的规则。”正确。
2. “价值函数只看当前一步奖励，完全不看未来。”错误。
3. “最优策略追求最大化期望累计奖励。”正确。

9.7 MDP 与马尔可夫性

复习重点：

1. MDP 是 Markov Decision Process，马尔可夫决策过程。
2. MDP 是强化学习常用数学模型。
3. 马尔可夫性指未来只依赖当前状态和动作，而不依赖完整历史。
4. 如果当前状态已经包含足够信息，就不需要再记住所有过去信息。
5. MDP 常包含状态、动作、转移概率、奖励、折扣因子等元素。

必背句：

马尔可夫性：给定当前状态和动作后，未来状态的概率分布与更早历史无关。

易错点：

1. “MDP 是马尔可夫决策过程。”正确。
2. “马尔可夫性要求未来依赖全部历史。”错误。
3. “当前状态如果足够完整，就可以用于预测下一状态分布。”正确。

9.8 Bellman 方程的直观含义

复习重点：

1. Bellman 方程刻画当前价值和未来价值的递推关系。

2. 当前状态的价值等于当前奖励加上折扣后的下一状态价值的期望。
3. Bellman 方程是许多强化学习算法的基础。
4. 不要求推导复杂公式，只要理解“当前价值 = 当前收益 + 未来价值”。

直观形式：

当前价值 = 当前奖励 + γ × 未来价值

不考虑动作时，向量形式：

$$V = R + \gamma P V$$

易错点：

1. “Bellman 方程把当前价值和未来价值联系起来。”正确。
2. “Bellman 方程完全不考虑未来。”错误。
3. “Bellman 方程是强化学习中的重要基础。”正确。

9.9 DP、MC 与深度强化学习

复习重点：

1. 动态规划 DP 可以利用 Bellman 方程迭代求价值。
2. DP 的优点是可以较精确计算价值。
3. DP 的缺点是通常要知道环境转移概率 P 。
4. 蒙特卡洛 MC 通过多次实验采样取平均。
5. MC 的优点是简单直接，不一定需要明确知道转移概率。
6. MC 的缺点是随机性大，方差可能大。
7. 深度强化学习把深度神经网络引入强化学习。
8. 深度神经网络可以近似价值函数或策略。
9. DQN 用神经网络替代表格来拟合 Q 值。
10. 深度强化学习能处理高维状态，如图像输入。
11. 深度强化学习也带来训练不稳定、数据需求大、算力需求高等问题。

对照表：

方法	核心思想	优点	缺点
DP	用 Bellman 方程迭代	可较精确计算	需要环境模型/转移概率
MC	多次采样取平均	简单直接	随机性大，方差可能大
DRL	用深度网络近似价值或策略	处理高维复杂状态	训练难、数据和算力需求大

易错点：

1. “DP 通常要知道转移概率。”正确。
2. “MC 通过采样估计价值。”正确。
3. “DQN 用神经网络近似 Q 值。”正确。
4. “深度强化学习完全没有训练困难。”错误。

9.10 强化学习应用

复习重点：

1. 强化学习可用于游戏 AI。
2. 强化学习可用于机器人控制。
3. 强化学习可用于自动驾驶、交通灯调度、推荐系统、数据中心节能等。
4. 大模型后训练中也可使用强化学习。
5. 在 ChatGPT 一类系统中，可以用人类偏好构造奖励信号。
6. 在推理模型中，强化学习可用于增强推理能力。

易错点：

1. “强化学习只能玩游戏。”错误。
2. “强化学习可以用于机器人控制。”正确。
3. “大模型后训练中可能使用强化学习。”正确。

9.11 思考题

1. 判断：强化学习中，智能体通过与环境交互，并根据奖励反馈学习。
答案：正确。
2. 填空：强化学习的目标通常是最大化期望 _____ 奖励。
答案：累计。
3. 计算：未来三个奖励为 1, 0, 2, $\gamma = 0.5$, 折扣回报为 _____。
答案： $1 + 0.5 \times 0 + 0.5^2 \times 2 = 1.5$ 。
4. 选择：尝试一个不确定但可能更好的动作，属于：A. 探索 B. 利用 C. 监督学习 D. 归一化。
答案：A。
5. 判断：马尔可夫性指给定当前状态和动作后，未来状态分布不再依赖更早历史。
答案：正确。

10 最后一遍串讲清单

10.1 残差网络必会

1. 深层普通网络可能出现退化问题。
2. 退化问题指网络加深后训练误差或测试误差反而变差。
3. 深层网络还可能遇到梯度消失和梯度爆炸。
4. 残差连接的基本形式是 $F(x) + x$ 。
5. 残差连接帮助信息和梯度在深层网络中传播。
6. ResNet 主要用于缓解深层网络训练困难和退化问题。

10.2 CNN 必会

1. 图像具有局部关联性和一定不变性。
2. 关联性会随距离衰减，课件中有指数衰减和幂级数衰减两类模型。
3. 幂级数衰减可以理解为许多指数衰减成分的叠加，长程关联更不容易完全消失。
4. CNN 与 MLP 的核心区别是局部连接和参数共享。
5. 卷积核在图像上滑动，用局部窗口提取边缘、方向、纹理等局部特征。
6. 卷积核参数通常随机初始化，然后训练得到。
7. RGB 输入有 3 个通道；输出通道数由卷积核个数决定。
8. 会根据输入大小、卷积核大小、padding、stride 计算输出空间尺寸；输出通道数等于卷积核个数。
9. 会根据卷积核大小、输入通道数、卷积核个数计算卷积层参数量。
10. 池化可以降低空间尺寸，逐渐处理更长范围的关联，通常不改变通道数。
11. CNN 可由卷积、激活、池化、展平、全连接、输出层等模块按任务需要组合。

10.3 RNN/LSTM 必会

1. NLP 是处理自然语言的任务。
2. 语言有顺序、上下文、长程依赖。
3. Tokenization 把文本切分成 token。
4. One-hot 稀疏且不表达语义相似。
5. Embedding 可训练，能学习词向量。
6. Next Token Prediction 是预测下一个 token。
7. RNN 能处理序列，因为有历史状态。
8. BPTT 训练 RNN，长序列可能梯度消失/爆炸。
9. LSTM 通过记忆状态和门控机制缓解长程依赖问题。

10.4 Transformer 必会

1. Transformer 核心是注意力机制。
2. Embedding 把 token 变向量。
3. 位置编码提供顺序信息。
4. Q/K/V 分别是 Query/Key/Value。
5. Q 和 K 算相关性，V 被加权求和。
6. Softmax 把注意力分数变成权重。
7. Causal mask 防止 Decoder 看未来。
8. LayerNorm 逐 token 归一化。
9. FNN 逐 token 作用。
10. 输出层映射到词表大小。

10.5 训练现象必会

1. 频率原则：先低频后高频。
2. 低频是轮廓、平滑、整体趋势。
3. 高频是细节、振荡、快速变化，也可能包含噪声。
4. 早停可以减少拟合高频噪声。
5. 初始化影响训练。
6. 小初始化可能导致参数凝聚。
7. 参数凝聚使多个神经元趋向相似偏好。
8. 平坦解通常更鲁棒、泛化更好。

10.6 大模型必会

1. 大模型又叫基础模型。
2. 大模型通常参数量大、数据规模大、适应任务多。
3. Encoder-only 常用于理解任务。
4. Decoder-only 常用于生成任务。
5. 当前主流生成式大语言模型多是 Decoder-only。
6. 预训练学习基础能力。
7. 微调用特定任务数据继续训练。
8. 提示词工程改变输入，不一定改参数。
9. 知识蒸馏把大模型知识迁移到小模型。
10. 上下文学习不更新权重。
11. 思维链生成中间推理步骤。
12. 大模型可能产生幻觉和偏见。

10.7 强化学习必会

1. 强化学习是决策型任务。
2. 基本循环：状态、动作、奖励、下一状态。
3. 目标是最大化期望累计奖励。
4. 状态是完整环境信息，观察是智能体看到的信息。
5. 动作空间可以离散或连续。
6. 折扣因子 γ 在 0 到 1 之间。
7. γ 越大越重视长期奖励。
8. 情节型任务有终点，连续型任务没有固定终点。
9. 探索是尝试未知，利用是使用已有知识。
10. 策略是选择动作的规则。
11. 价值函数衡量状态的期望回报。
12. MDP 是马尔可夫决策过程。
13. 马尔可夫性：未来只依赖当前状态和动作。
14. Bellman 方程联系当前价值和未来价值。
15. DP 需要环境模型，MC 通过采样估计。

16. 深度强化学习用神经网络近似价值函数或策略。

11 不建议作为考试重点的内容

以下内容可以课堂提到，但不建议作为选择、判断、填空题重点。

1. 卷积平移等变性的严格证明。
2. Pooling 反向传播细节。
3. LSTM 门控公式完整推导。
4. 正余弦位置编码、RoPE、相对位置编码的公式推导。
5. 多头注意力复杂矩阵维度计算。
6. 多尺度神经网络、Fourier 特征、NeRF。
7. Hessian、稳定边缘的数学推导。
8. LoRA、MCP、Agent、RAG 的技术细节。
9. TD、Sarsa、Q-learning 的公式推导。
10. Kaggle 注册、实验提交、代码复现操作。

12 两节复习课建议讲法

12.1 第一节课：网络结构主线

建议顺序：

1. 5 分钟：说明考试范围和“不考阅读材料”。
2. 10 分钟：残差网络，重点讲退化问题、梯度传播困难和残差连接。
3. 30 分钟：CNN，按“图像数据特点 -> 为什么需要卷积 -> 卷积/padding/stride/池化计算 -> 经典结构”讲。
4. 20 分钟：RNN/LSTM，重点讲序列、BPTT、梯度问题、门控机制。
5. 25 分钟：Transformer，重点讲 embedding、位置编码、QKV、mask、输出层。

课堂建议：

1. CNN 部分一定要带学生完整算 2-3 个尺寸题。
2. Transformer 部分不要推矩阵公式，重点讲 Q/K/V 的角色。
3. RNN/LSTM 部分不要推门控公式，重点讲为什么需要记忆和门。

12.2 第二节课：训练现象、大模型、强化学习

建议顺序：

1. 20 分钟：频率原则、早停、初始化、凝聚、平坦解。
2. 20 分钟：大模型架构、预训练、微调、提示词、蒸馏、scaling law、上下文学习、思维链。
3. 35 分钟：强化学习基本概念、回报计算、探索利用、MDP、Bellman、DP/MC/DRL。
4. 15 分钟：串讲易错点。

课堂建议：

1. 训练现象部分用“先学轮廓再学细节”来讲频率原则。
2. 大模型部分重点做概念辨析，不要展开最新技术细节。
3. 强化学习部分要反复画“状态-动作-奖励-下一状态”的循环。
4. Bellman 方程只讲“当前价值 = 当前奖励 + 折扣未来价值”。